

DATATHON 4TA EDICIÓN

Anticipando el futuro financiero con Hey Banco

Presentado por el equipo dinamita
conformado por Anna Galilea Restrepo
Martínez, Jorge Eduardo Avila Montoya y
Diego Villarreal

Problemas detectados



- 1 99% de los usuarios tienen patrones de gasto repetitivos, pero la app no los aprovecha.
- 2 No existe un espacio en la app que muestre próximos pagos estimados ni acción sugerida.
- 3 No se aprovecha el historial transaccional para personalizar la experiencia del usuario.

Solución propuesta

- Módulo “Próximos movimientos” integrado al navbar.
- Predice:
 - Qué gasto hará el cliente
 - Cuándo lo hará
 - Cuánto gastará
- Se despliega como una tabla tipo dashboard con la información de: comercio, fecha estimada y monto esperado.
- También se puede implementar una racha o mecánicas de gamificación.
- Mejora la experiencia del usuario y promueve el uso de la tarjeta.

Además, según el uso frecuente del cliente con su tarjeta, se muestra una acción de negocio sugerida personalizada:


- Ultra constantes (12/12 meses): Premios exclusivos, upgrades de cuenta, cashback, lealtad
- Regularmente frecuentes (cada 2–3 meses): Automatización de pagos, promociones por recurrencia
- Gastos erráticos o casi nulos: Alertas personalizadas, campañas de retención, análisis de fuga



Cómo funciona

Para construir el módulo de “Próximos movimientos”, seguimos una metodología estructurada en distintas fases, combinando reglas, visualizaciones y modelos predictivos.

- Limpieza de datos
 - Unificación de las bases de datos
 - Variable año-mes
- Detección de recurrencias cliente-comercio
 - Conteo de meses distintos de incidencia por negocio
 - Decisión de la regla e histograma
- Clasificación de clientes acorde a sus transacciones
 - Regla para elegir si un cliente es recurrente
 - Histograma y decisión
- Modelos de predicción
 - Siguiendo comercio
 - Siguiendo monto por comercio
 - Siguiendo fecha por comercio



```

from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error
from sklearn.metrics import median_absolute_error

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=49)

rf = RandomForestRegressor(n_estimators=100, n_jobs=-1, random_state=49)
rf.fit(X_train, y_train)

preds = rf.predict(X_test)
mae = mean_absolute_error(y_test, preds)
medae = median_absolute_error(y_test, preds)
print(f"MAE mejorado: {mae:.2f} días")
print(f"Median Absolute Error: {medae:.2f}")
r2 = r2_score(y_test, preds)

print(f"R² del modelo: {r2:.4f}")

```

[9]

```

... MAE mejorado: 5.63 días
    Median Absolute Error: 2.43
    R² del modelo: 0.3631

```

```

from sklearn.preprocessing import OneHotEncoder
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split

# One-hot para giro_comercio (o comercio actual)
X = base_no_recurrente[['giro_comercio', 'monto']].copy()
X = pd.get_dummies(X, columns=['giro_comercio'])

y = base_no_recurrente['comercio_siguiente']

# Split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Modelo
clf = RandomForestClassifier(n_estimators=100, random_state=42)
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)
print(f"Accuracy en test: {clf.score(X_test, y_test):.2f}")

```

✓ 6.2s

Accuracy en test: 0.53

```

from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error
import numpy as np
from sklearn.metrics import r2_score
import pandas as pd

y_monto = base_modelo['monto_siguiente']

X_train_m, X_test_m, y_train_m, y_test_m = train_test_split(X, y_monto, test_size=0.2, random_state=42)

reg = RandomForestRegressor(n_estimators=100, random_state=42)
reg.fit(X_train_m, y_train_m)

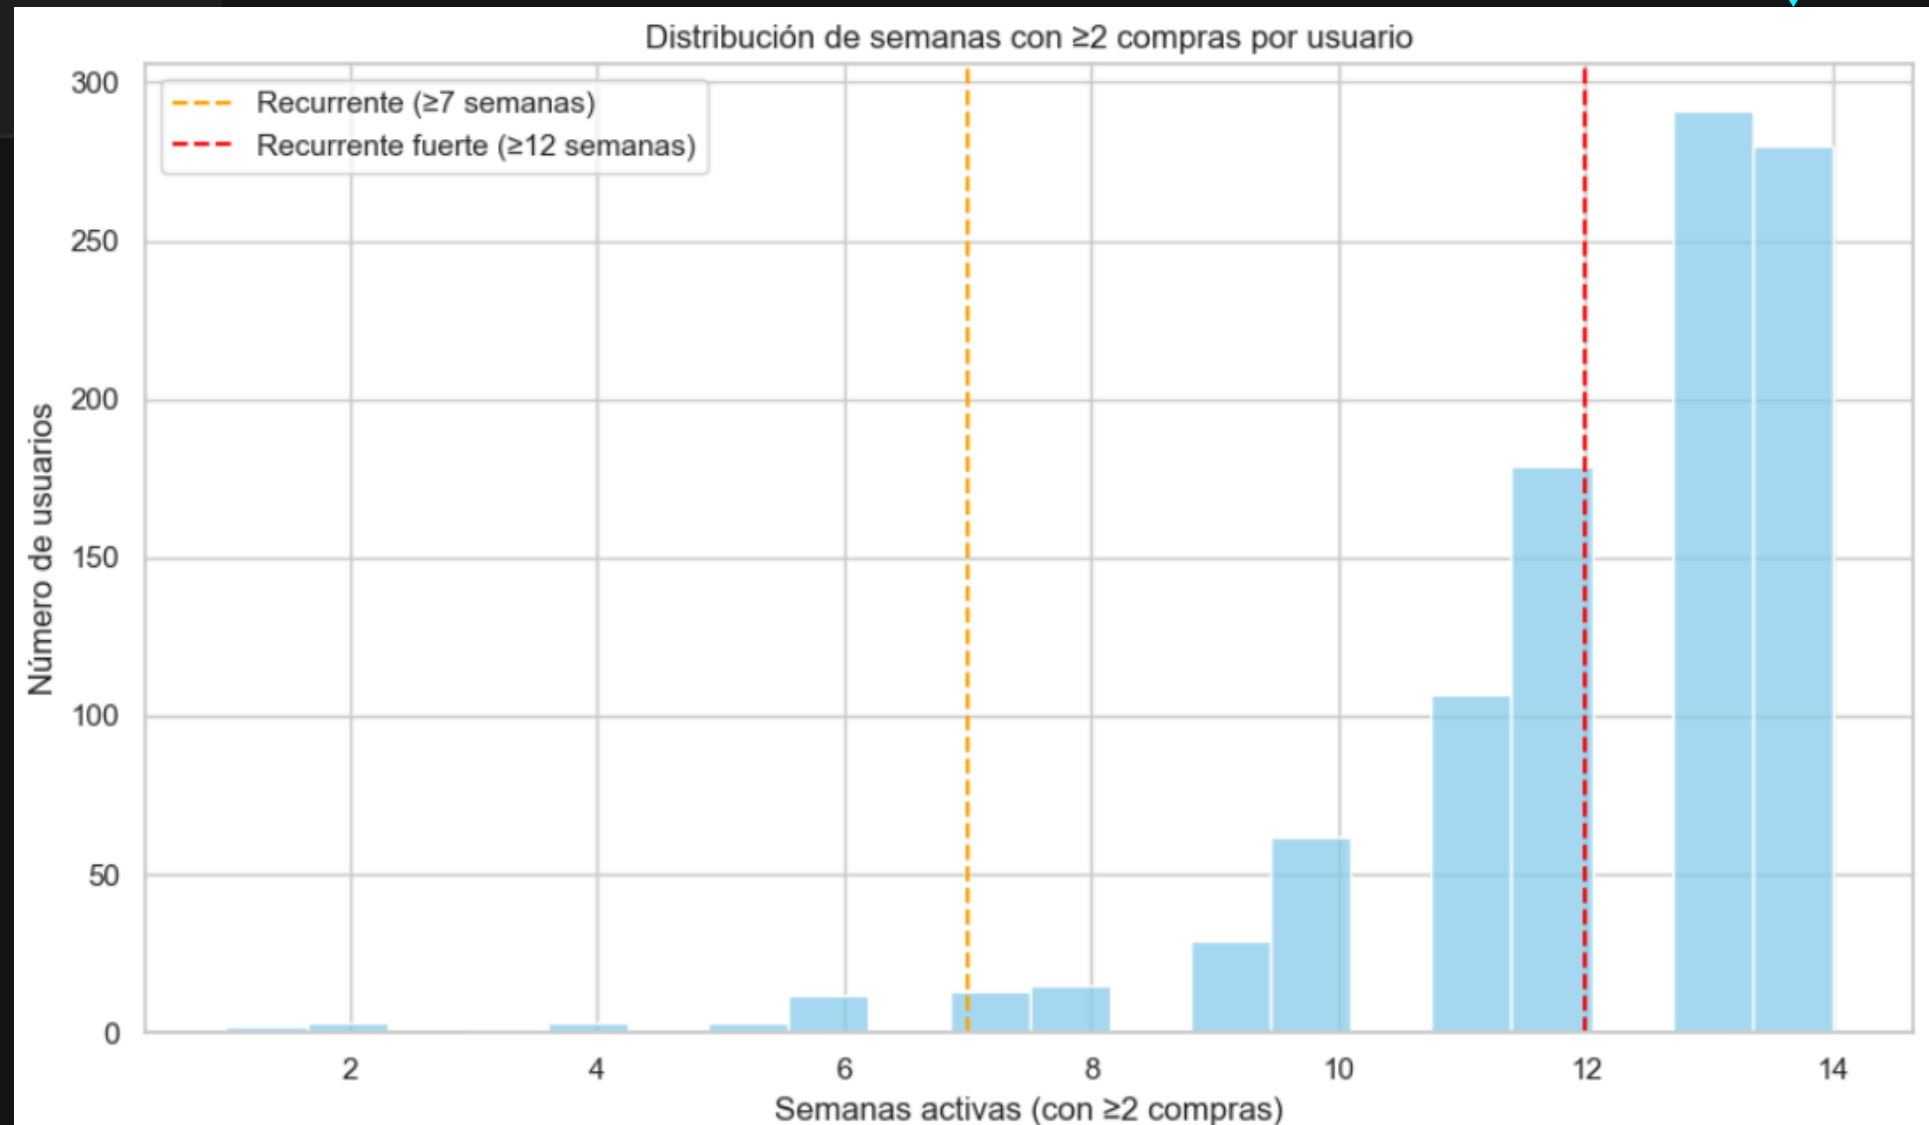
preds = reg.predict(X_test_m)
mse = mean_squared_error(y_test_m, preds)
rmse = np.sqrt(mse)

print(f"RMSE del monto siguiente: {rmse:.2f}")
# Supón que ya tienes tu modelo entrenado y predicciones hechas
r2 = r2_score(y_test_m, preds)
print(f"R² del modelo: {r2:.4f}")

```

RMSE del monto siguiente: 38.56

R² del modelo: 0.2818



Comercio

	Actual	Predicted
128212	FARMACIAS GUADALAJARA	FARMACIAS GUADALAJARA
273458	UBER EATS	UBER EATS
77981	RAPPI	RAPPI
266340	AMAZON	AMAZON
223167	AMAZON	AMAZON
...
29454	DIDI	DIDI RIDES
60611	OXXO	OXXO
183420	SPOTIFY	SPOTIFY
320984	SORIANA	7 ELEVEN
112648	DIDI FOOD	UBER EATS

Monto

	Actual	Predicted
128212	9.32	20.578472
273458	18.51	25.669300
77981	37.08	60.218740
266340	34.59	17.070088
223167	34.71	51.910100
...
29454	6.33	14.028623
60611	15.18	8.972482
183420	23.10	22.568760
320984	39.34	35.108900
112648	17.85	20.276910


Dias

	Actual	Predicted
21593	1.0	1.140000
7483	30.0	25.605000
7250	1.0	2.515333
30338	0.0	4.731500
1174	13.0	16.460000
...
7606	17.0	14.798000
32549	1.0	3.692667
20862	12.0	4.263333
28532	34.0	3.742667
22021	28.0	28.020000

		Recurrentes Fuertes	Recurrentes	No recurrentes
Siguiente Comercio	Precisión	0.53	0.31	0.21
Siguiente Monto	RMSE	38.56	38.15	136.72
	R2	0.2818	0.1449	0.1013
Siguiente Fecha	MAE	6	5.63	17.57
	Median AE	3.61	2.43	7.42
	R2	0.4026	0.3631	0.4259



Valor para el negocio

- Genera oportunidades de venta cruzada (Hey Pro, Hey Coins)
- Reduce el riesgo de fuga en perfiles inactivos
- Mejora el uso de la tarjeta como método de pago principal



Extensiones futuras

- Integración con HAVI (asistente virtual): "Havi, ¿cuándo pagaré Amazon?"
- Activación de recordatorios o pagos automáticos
- Gamificación: badges por comportamiento financiero ejemplar
- Dashboards para usuarios o analistas internos



Thank You

